

UNIVERSIDADE FEDERAL FLUMINENSE  
PROGRAMA DE PÓS-GRADUAÇÃO EM COMPUTAÇÃO  
ESTIMAÇÃO DE ESTADO

Luiz Phillip Quintanilha da Silva

Neste relatório será apresentado o uso da aplicação desenvolvida para a Estimação de Estado (EE). O programa contém as principais ferramentas estudadas na disciplina de EE ministrada pelo professor Julio Cesar Stachchini De Souza no segundo semestre de 2020. O programa foi testado no sistema do IEEEE 14 Barras para sistemas de transmissão.

A Estimação de Estado é um processo iterativo em que dados um conjunto de medições instaladas em valor e designado para as variáveis de estado do sistema com base em processo iterativo. Como os erros são inerentes ao processo de medição a redundância torna-se necessária. Na EE para sistemas elétricos de potência é usual minimizar a função de custo conhecida como Mínimos Quadrados Ponderados.

Mínimos Quadrados Ponderados

Conforme mencionado anteriormente a função que se deseja minimizar para a EE é a Mínimos Quadrados Ponderados. Esta função, designada pela letra  $J$  está representada na Equação (1)

$$J(x) = \sum_{i=1}^N \frac{(z_i - h_i(x))^2}{R_{ii}} \tag{1}$$

onde  $z_i$  representa o valor medido,  $h_i$  é uma função não linear que relaciona o estado estimado  $x$  com a medida e  $R_{ii}$  representa a variância da medida.

A Equação (1) difere dos mínimos quadrados comum por considerar a variância da medição. Esta função é considerada uma função de maximização da verossimilhança quando avaliada sobre uma distribuição normal.

É interessante notar que  $J(x) \sim \chi^2$ . Desta forma, pode-se avaliar a qualidade da EE a partir de um teste de hipótese. Se ao final da estimação a função de custo está acima do valor da  $\chi^2$  para um nível de confiança  $\alpha$ , então pode-se investigar a presença de dados errôneos ou de erro(s) no(s) parâmetro(s)topologia da rede. Vale ressaltar que em geral este método não é muito utilizado.

Processo de Estimação de Estado

A EE utiliza as medições disponíveis no sistema para estimar as variáveis de estado mais prováveis da rede. Este processo utiliza a Equação (1) para maximizar a verossimilhança entre as medições recebidas e as estimadas. Para tal tarefa defini-se uma função  $g(x)$  que será responsável pela minimização de  $J(x)$ . Para esta minimização  $g(x)$  será dada por:

$$g(x) = \frac{\partial J}{\partial x} = -H^T(x)^T R^{-1} [z - h(x)] \tag{2}$$

em que  $H(x) = \frac{\partial h}{\partial x}$

Expandindo  $g(x)$  em série de Taylor e considerando somente o termo de primeira ordem obtém-se a Equação (3):

$$[G(x^k)] \Delta x^{k+1} = H^T(x^k) R^{-1} [z - h(x^k)] \tag{3}$$

em que  $G(x)$  é conhecida como matriz de ganho e definida como  $G(x) = \frac{\partial^2 J}{\partial x^2}$

Por ser um processo iterativo, o estado estimado é determinado quando  $|\Delta x|$  é menor que uma tolerância determinada. Neste caso é dito que o processo convergiu. A Equação (4) apresenta esse critério de parada.

$$|\Delta x^k| \leq \epsilon \tag{4}$$

Criticalidade - Medidas e Conjuntos

As medidas críticas e os conjuntos críticos podem ser obtidos a partir do EE linear. A criticalidade é um problema de característica topológica, então os valores das medidas e das admittâncias não são necessários. A principal característica das medidas críticas é que tanto o resíduo da estimação quanto o desvio padrão são iguais a zero. Desta forma, não é possível identificar erros presentes nas medidas críticas, além disso caso esta medida torne-se indisponível o sistema será dito não observável. Já as medidas pertencentes aos conjuntos críticos possuem tanto correlação máxima entre os resíduos quanto igualdade entre os resíduos normalizados. Neste caso, é possível detectar a presença de medidas errôneas, porém a identificação não pode ser realizada.

Outra característica que vale ressaltar é que quando se perde uma medida pertencente a algum conjunto crítico, todas as medidas daquele conjunto tornam-se críticas.

Em resumo, para a identificação das medidas críticas e dos conjuntos críticos:

- Medidas Críticas:
$$r_i = r_i^N = 0$$
- Conjuntos Críticos:
$$\rho = \frac{r_i^N}{r_i^N} = 1$$
$$\gamma = \frac{|R_{ii}|}{\sqrt{E_i} \sqrt{E_k}} = 1$$

Bibliotecas e Funções

- Pandas - Biblioteca padrão do python para trabalhar com dados tabulares
- Numpy - Biblioteca padrão do python para trabalhar com dados numéricos
- Matplotlib - Biblioteca padrão do python para trabalhar com gráficos
- MSPSS - Função criada para o processo da Estimação de Estado

In [1]:

```
from PSSS import
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
```

Parâmetros das Linhas da rede teste

In [2]:

```
line_params = 'Dados_linha_XIV_barras.xlsx'
pd.read_excel(line_params)
```

Out [2]:

	De	Para	R	X	C	Tap
0	1	2	0.01938	0.05917	18.939394	0
1	1	5	0.05403	0.22304	20.325203	0
2	2	3	0.04699	0.19797	22.831050	0
3	2	4	0.05811	0.17632	26.737968	0
4	2	5	0.05995	0.17388	29.411765	0
5	3	4	0.06701	0.17103	28.901734	0
6	4	5	0.01335	0.04211	78.125000	0
7	4	9	0.00000	0.20912	0.000000	0
8	4	9	0.00000	0.55618	0.000000	0
9	5	6	0.00000	0.25202	0.000000	0
10	6	11	0.09498	0.19890	0.000000	0
11	6	12	0.12291	0.25581	0.000000	0
12	6	13	0.06615	0.13027	0.000000	0
13	7	8	0.00000	0.17615	0.000000	0
14	7	9	0.00000	0.11001	0.000000	0
15	10	0.03181	0.08450	0.000000	0	
16	9	14	0.12711	0.27938	0.000000	0
17	10	11	0.06205	0.19207	0.000000	0
18	12	13	0.22092	0.19988	0.000000	0
19	13	14	0.17093	0.34082	0.000000	0

Medições disponíveis na rede

In [3]:

```
measured_file = 'Measured_data_XIV_bus.xlsx'
pd.read_excel(measured_file)
```

Out [3]:

	Tipo	De	Para	Valor	Desvio_Pad
0	P	1	-	1.2680	0.016125
1	P	2	-	0.1564	0.012247
2	P	2	1	-0.8613	0.017321
3	P	1	5	0.4354	0.014491
4	P	2	3	0.4628	0.014632
5	P	2	4	0.3406	0.013784
6	P	5	2	-0.2439	0.013038
7	P	3	4	-0.1982	0.013038
8	P	4	5	-0.3882	0.014491
9	P	7	4	-0.2079	0.013038
10	P	4	9	0.1308	0.012247
11	P	5	6	0.3203	0.013784
12	P	11	6	-0.0291	0.011832
13	P	6	12	0.0432	0.011832
14	P	6	13	0.0629	0.012247
15	P	7	8	-0.0049	0.011832
16	P	9	7	-0.1922	0.013038
17	P	9	10	0.0328	0.011832
18	P	14	9	-0.0408	0.011832
19	P	10	11	-0.0186	0.011832
20	P	13	12	0.0004	0.011832
21	P	13	14	0.0244	0.011832
22	Q	1	-	-0.0759	0.011832
23	Q	2	-	-0.1262	0.012247
24	Q	2	1	0.0015	0.011832
25	Q	1	5	-0.0486	0.011832
26	Q	2	3	0.0766	0.012247
27	Q	2	4	-0.1233	0.012247
28	Q	5	2	0.0832	0.012247
29	Q	3	4	-0.1012	0.012649
30	Q	4	5	0.0097	0.011432
31	Q	7	4	0.1381	0.012649
32	Q	4	9	-0.0840	0.011832
33	Q	5	6	-0.0922	0.012247
34	Q	11	6	-0.0361	0.011832
35	Q	6	12	0.0276	0.011832
36	Q	13	0.0380	0.011832	
37	Q	7	8	-0.1227	0.012649
38	Q	9	7	-0.0297	0.011832
39	Q	9	10	0.0126	0.011832
40	Q	14	9	-0.0111	0.011832
41	Q	10	11	0.0055	0.011832
42	Q	13	12	0.0027	0.011832
43	Q	13	14	0.0259	0.011832
44	V	1	-	1.0551	0.003162
45	V	2	-	1.0468	0.003162

Executando a função state\_estimation(). Esta função retorna:

- $y_{bus\_matrix}$  - Matriz Y Barra do sistema
- $criticality\_data$  - Dados Relacionados a Criticalidade das medidas
- $J\_list$  - Função de custo ao longo do processo iterativo
- $J\_critical$  - Valor crítico da função de custo
- $State\_dataframe$  - Dados do Estado estimado com as medidas disponíveis
- $data\_SE$  - Dados Relacionados as medidas estimadas

In [4]:

```
y_bus_matrix, criticality_data, J_list, J_critical, State_dataframe, data_SE = state_estimation(line_params = line_params, measured_file = measured_file)
```

Visualização da Matriz  $Y_{bus}$  obtida pelo programa state\_estimation

$$Y_{bus} = Z^{-1}_{bus}$$

In [5]:

```
amount_bus = y_bus_matrix.shape[0]
bus = range(1, amount_bus+1)
fig = Figure(figsize=(5, 5), dpi=100)
fig.dataframe(y_bus_matrix, index = bus, columns = bus).style.format("{:.1f}").format().set_properties(**{'font-size': '8pt'})
```

Out [5]:

	1	2	3	4	5	6	7	8	9	10	11	12	13	14
1	6.0-19.4j	-0.0+1.3j	0.0+0.0j	0.0+0.0j	-1.0+4.2j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j
2	-5.0+15.3j	9.5-30.3j	-1.1+4.8j	-1.7+5.1j	-1.7+5.2j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j
3	0.0+0.0j	-1.1+4.8j	3.1+8.3j	-2.0+5.1j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j
4	0.0+0.0j	-1.7+5.1j	-2.0+5.1j	10.5-38.3j	-6.8+21.6j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+1.8j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j
5	-1.0+4.2j	-1.7+5.2j	0.0+0.0j	-6.8+21.6j	9.6-34.9j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j
6	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	6.6-17.3j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	-2.0+4.1j	-1.5+3.2j	-3.1+6.1j	0.0+0.0j
7	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	6.6-17.3j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j
8	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j
9	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	5.3-24.3j	-3.9+10.4j	0.0+0.0j	0.0+0.0j	0.0+0.0j	-1.4+3.0j
10	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	5.8-14.8j	-1.9+4.4j	0.0+0.0j	0.0+0.0j
11	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	-2.0+4.1j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j
12	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j
13	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j
14	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j
15	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j	0.0+0.0j

Medidas Críticas e Conjuntos Críticos calculados pelo programa a partir do estimador de estado linear.

In [6]:

```
criticality_data.dropna().sort_values(by='Criticality')
```

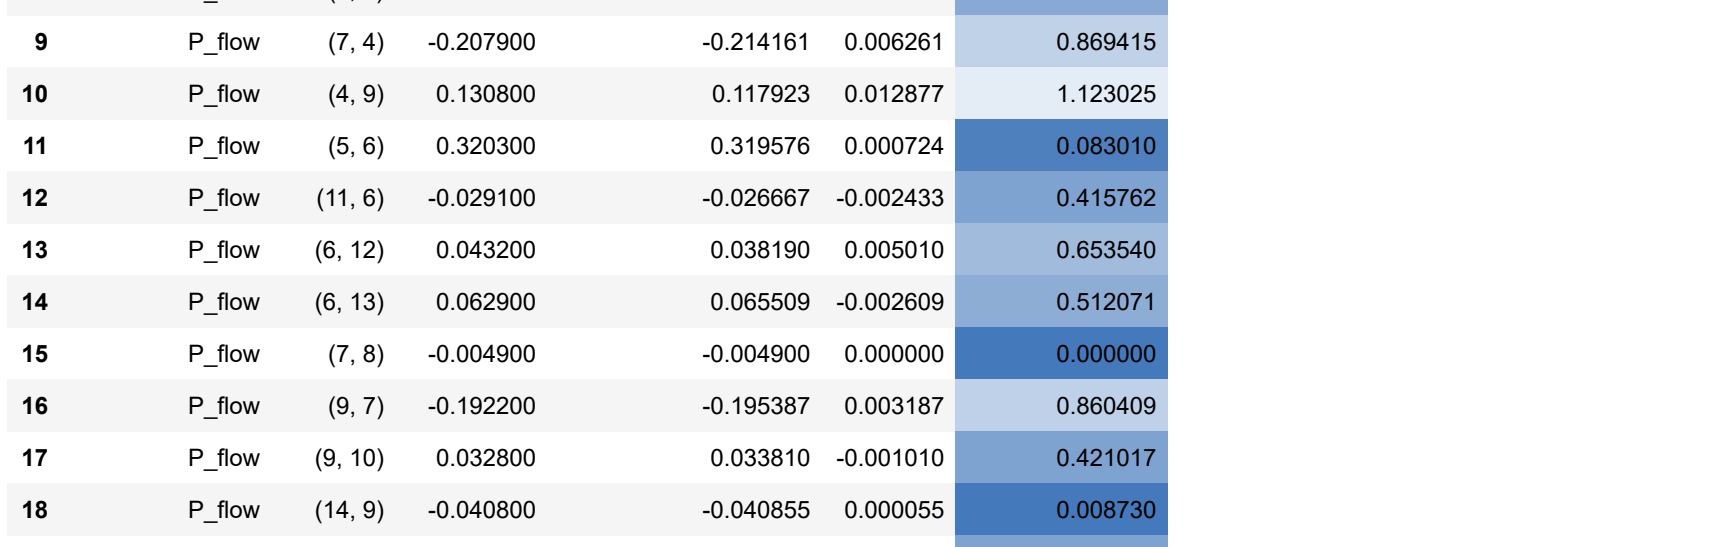
Out [6]:

	Measured_Type	Location	Criticality
9	P_flow	(7, 4)	CSets_1
16	P_flow	(9, 7)	CSets_1
12	P_flow	(11, 6)	CSets_2
17	P_flow	(9, 10)	CSets_2
13	P_flow	(10, 11)	CSets_2
19	P_flow	(6, 12)	CSets_3
20	P_flow	(13, 12)	CSets_3
21	P_flow	(14, 9)	CSets_4
18	P_flow	(13, 14)	CSets_4
15	P_flow	(7, 8)	Critical Measured

Evolução da função de custo ao longo do processo iterativo da EE. Pode-se notar que o valor de  $J(x)$  está abaixo do valor crítico. Desta forma, não há motivos para se rejeitar a hipótese nula  $H_0$  de que não há medidas ruins utilizando  $\alpha = 0.05$ .

In [7]:

```
plt.figure(figsize=(17, 8))
iteracoes = range(1, len(J_list)+1)
plt.plot(iteracoes, J_list, color = 'royalblue', lw = 2, label = 'Função de Custo')
plt.axhline(J_critical, color = 'black', ls = '--', label = 'Valor Crítico da Função de Custo')
plt.yscale('log')
plt.legend()
plt.xlabel('Iterações', fontsize = 12)
plt.ylabel('Função de Custo - Escala Log', fontsize = 12)
plt.title('Evolução da Função de Custo ao longo das Iterações', fontsize = 12)
plt.show()
```



Módulo da Tensão e Ângulo estimados pelo EE. A Barra 1 foi considerada como referência angular do sistema

In [8]:

```
pd.options.display.float_format = "{:,.3f}".format
State_dataframe
```

Out [8]:

	Voltage Mag.	Angle [Deg]
1	1.059	0.000
2	1.044	-2.634
3	1.011	-7.322
4	1.042	-5.683
5	1.046	-5.009
6	1.073	-9.124
7	1.068	-8.190
8	1.089	-8.147
9	1.065	-9.272
10	1.063	-9.396
11	1.064	-9.216
12	1.063	-9.461
13	1.065	-9.434
14	1.056	-9.712

Medidas Estimadas, Erro e Erro Normalizado para o processo iterativo da EE. Pode-se notar que todos os erros encontram-se abaixo do limiar padrão de 3. Assim, não há motivo para acreditar que há problemas no processo de medição.

OBS: Uma coloração divergente foi utilizada na coluna de erro normalizado. Tendo erros mais altos tendendo a cor vermelho e erros mais baixos tendendo a cor azul.

In [9]:

```
import seaborn as sns
cmmap=sns.diverging_palette(230, 5, as_cmap=True)
data_SE.style.background_gradient(cmmap, subset=('Error_Normalize'))
```

Out [9]:

	Measured_Type	Location	Measured	Measured Estimated	Error	Error_Normalize
9	P_hj	1	1.268000	1.362144	-0.096147	9.586303
1	P_hj	2	0.156400	0.165357	-0.008957	1.788094
2	P_flow	(2, 1)	-0.861300	-0.847507	-0.013793	0.919651
3	P_flow	(1, 5)	0.435400	0.428190	0.007210	0.522682
4	P_flow	(2, 3)	0.462800	0.456335	0.006465	0.520301
5	P_flow	(2, 4)	0.340600	0.332045	0.017555	1.371557
6	P_flow	(5, 2)	-0.243900	-0.230285	-0.013615	1.131339
7	P_flow	(3, 4)	-0.198200	-0.195457	-0.002743	0.386135
8	P_flow	(4, 5)	-0.388200			



In [20]: data\_SS.style.background\_gradient(cmap, subset=['Error\_Normallize'])

Out[20]:

	Measured Type	Location	Measured	Measured Estimated	Error	Error_Normallize
0	P_hj	1	1.266000	1.261470	-0.025470	2.556429
1	P_hj	2	0.156400	0.148190	-0.008210	1.610086
2	P_flow	(2, 1)	-0.861300	-0.713464	-0.147836	9.548050
3	P_flow	(1, 5)	0.435400	0.568971	-0.133571	10.257536
4	P_flow	(2, 3)	0.462800	0.349484	0.113316	8.336439
5	P_flow	(2, 4)	0.340600	0.317647	0.022953	1.771602
6	P_flow	(5, 2)	-0.243900	-0.192446	-0.051454	4.104606
7	P_flow	(3, 4)	-0.198200	-0.250874	0.052674	10.040389
8	P_flow	(4, 5)	-0.388200	-0.409873	0.021673	7.614648
9	P_flow	(7, 4)	-0.207900	-0.213213	0.005313	0.737952
10	P_flow	(4, 9)	0.130800	0.117482	0.013318	1.161486
11	P_flow	(5, 6)	0.320300	0.321090	-0.000790	0.090595
12	P_flow	(11, 6)	-0.029100	-0.027283	-0.001817	0.310420
13	P_flow	(6, 12)	0.043200	0.038226	0.004974	0.648935
14	P_flow	(6, 13)	0.063900	0.065656	-0.002756	0.540980
15	P_flow	(7, 8)	-0.004900	-0.004900	0.000000	0.000000
16	P_flow	(9, 7)	-0.192200	-0.194900	0.002700	0.728919
17	P_flow	(9, 10)	0.032800	0.033547	-0.002747	0.311464
18	P_flow	(14, 9)	-0.040800	-0.040526	-0.000274	0.043327
19	P_flow	(10, 11)	-0.018600	-0.018666	-0.0001734	0.311323
20	P_flow	(13, 12)	0.000400	0.008341	-0.005941	0.733433
21	P_flow	(13, 14)	0.024400	0.024456	-0.000056	0.007004
22	Q_hj	1	-0.075900	-0.082491	0.006591	0.912183
23	Q_hj	2	-0.126200	-0.123691	-0.002509	0.419878
24	Q_flow	(2, 1)	0.001500	-0.019981	0.021311	2.082640
25	Q_flow	(1, 5)	-0.048600	-0.086075	0.037475	3.550576
26	Q_flow	(2, 3)	0.076900	0.043744	0.032856	3.050378
27	Q_flow	(2, 4)	-0.123300	-0.084453	-0.038847	3.369980
28	Q_flow	(5, 2)	0.083200	0.037457	0.045743	3.875753
29	Q_flow	(3, 4)	-0.101200	-0.104871	0.003671	0.586292
30	Q_flow	(4, 5)	0.009700	0.014174	-0.004474	2.046990
31	Q_flow	(7, 4)	0.138100	0.141262	-0.003162	0.461645
32	Q_flow	(4, 9)	-0.064000	-0.041013	-0.022987	2.065516
33	Q_flow	(5, 6)	-0.092200	-0.099501	0.007301	0.983387
34	Q_flow	(11, 6)	-0.038100	-0.036231	0.000131	0.021308
35	Q_flow	(6, 12)	0.027600	0.024884	0.002716	0.353905
36	Q_flow	(6, 13)	0.038000	0.035532	0.002468	0.514594
37	Q_flow	(7, 8)	-0.122700	-0.122700	0.000000	0.000000
38	Q_flow	(9, 7)	-0.029700	-0.028071	-0.001629	0.500588
39	Q_flow	(9, 10)	0.012900	0.012902	-0.000002	0.000940
40	Q_flow	(14, 9)	-0.011100	-0.019097	0.007997	1.240202
41	Q_flow	(10, 11)	0.005500	0.005430	0.000070	0.012096
42	Q_flow	(13, 12)	0.002700	0.003362	-0.000662	0.081155
43	Q_flow	(13, 14)	0.025900	0.015870	0.010030	1.240883
44	V	1	1.055100	1.059257	-0.004157	1.848314
45	V	2	1.046800	1.044991	0.001809	0.807090

In [ ]: